

Model Validation Report — 信用评分卡建模与验证报告

数据来源: `data/loan_dataset_20000.csv` | 建模函数来源: `utils/risk_skills.py` | 调优来源: `scripts/tune_lgb_skill.py` | 随机种子: `random_state=42` 流水线: `scripts/train.py` (训练 + Optuna 调优, 仅接触 Train 集) → `scripts/test.py` (评估、混淆矩阵与报告生成, 仅接触 Test 集与已持久化模型)

1. Executive Summary

- 本次基于 `data/loan_dataset_20000.csv` (20,000 笔贷款样本) 构建了标准信用评分卡模型 (逻辑回归, `train_scorecard_model`, Baseline), 并通过 Optuna 贝叶斯超参数寻优 (`tune_lightgbm_optuna`, 50 轮, 5 折交叉验证, 优化目标 AUC) 得到单调约束 LightGBM 最优模型 (Champion)。
- 目标变量 `default = 1 - loan_paid_back` (1 = 违约/未还清, 0 = 正常还清)。
- 最优模型 (Optuna 调优 LightGBM) 在 Test 集上的判别能力: AUC = **0.8858** (阈值 ≥ 0.7 : **PASS**), KS = **0.5777** (阈值 ≥ 0.3 : **PASS**), 评级为 "Good (0.40 - 0.60)"; 混淆矩阵详见 §5.3。
- 基线评分卡 (逻辑回归) Test 集: AUC = 0.8812, KS = 0.5717, 作为可解释性对照。
- 最优模型预测违约概率在 Train → Test 上的 PSI = **0.0021**, 稳定性状态: "Stable (<0.10) - No action needed" (低于预警阈值, 无需特别处理)。
- 特征工程阶段基于 IV 剔除 14 个弱预测特征; 基于迭代式 VIF 剔除 1 个共线性特征; 最终入模特征 6 个 (详见 §3)。
- 治理标记 (保留, 非剔除): 特征 `employment_status` 的 IV 落入 "Suspicious / Overfitting (>0.5)" 区间 (详见 §3.1、§7.4), 存在近似确定性分组 (如 `employment_status=Unemployed` 违约率 81.8%、`Retired` 违约率仅 0.5%)。经复核判断为起贷时可得的合法申请人属性而非标签泄漏, 予以保留入模; 但其对模型判别力的贡献占比过高 (详见 §7.4 的敏感性对比), 存在集中度风险与潜在公平信贷 (fair-lending) 合规风险, 在独立验证与公平信贷复核完成前不建议直接投产使用。
- 方法论修正记录: 此前版本的多重共线性过滤为一次性剔除所有 VIF 超阈值特征, 导致 `credit_score` 因与 `grade_subgrade` 共同存在而被误伤剔除 (二者共线, 但只需剔除其一); 现改为迭代式 VIF (每轮只剔除当前 VIF 最高的单个特征后重新计算, 详见 §3.2), 该问题已修正。
- 调优脚本已知局限: `tune_lightgbm_optuna` 的最终模型使用交叉验证得到的最佳

超参数在全量 Train 上重新拟合，但重新拟合时固定 `n_estimators=1000` 且未设置 `eval_set` /早停，与各折验证时实际使用的早停树数不一致，可能引入额外方差；如需更严谨的复现，建议后续为最终拟合补充早停或将 CV 中位数最优轮数固定为 `n_estimators`。

- 建议：该最优模型判别能力与稳定性均满足内部风控标准；在完成 §7.4 所述的独立验证与公平信贷复核前，暂不建议投产。

2. Train / Test Split

- 数据源：`data/loan_dataset_20000.csv`，共 20,000 条样本，22 个原始字段（含目标衍生前）。
- 目标变量：`default`（由 `loan_paid_back` 取反得到，1 = 违约）。
- 切分方式：`sklearn.model_selection.train_test_split`（`scripts/train.py`），`test_size=0.3`，按目标变量分层抽样，`random_state=42`；切分结果持久化为 `artifacts/train_data.csv` / `artifacts/test_data.csv`，`scripts/test.py` 直接加载，不重新切分。
- 分层校验：Train / Test 违约率差异 < 0.001（见下表），分层抽样有效。
- 说明：原始数据不含时间/放款日期字段，无法构建真正意义上的跨时间 OOT 样本；本报告中的 "Test" 集为分层随机切分得到的样本外测试集，Optuna 调优过程中的 5 折交叉验证同样只在 Train 集内部进行，Test 集全程未参与调参或训练。

sample	n	bad_rate
Train	14000	0.2001
Test	6000	0.2002

3. Feature Engineering & Selection

3.1 WOE / IV 筛选表（基于 Train 集，`calculate_woe_iv`，等频 5 分箱，`scripts/train.py`）

feature	iv	predictive_power
employment_status	1.9096	Suspicious / Overfitting (>0.5)
debttoincome_ratio	0.3211	Strong (0.3 - 0.5)
grade_subgrade	0.2755	Medium (0.1 - 0.3)
credit_score	0.2601	Medium (0.1 - 0.3)
interest_rate	0.08	Weak (0.02 - 0.1)
delinquency_history	0.041	Weak (0.02 - 0.1)
numofdelinquencies	0.0317	Weak (0.02 - 0.1)
loan_purpose	0.0073	Unpredictive (<0.02)
education_level	0.0037	Unpredictive (<0.02)
monthly_income	0.003	Unpredictive (<0.02)
annual_income	0.003	Unpredictive (<0.02)
loan_amount	0.0022	Unpredictive (<0.02)
current_balance	0.0022	Unpredictive (<0.02)
numofopen_accounts	0.0021	Unpredictive (<0.02)
installment	0.002	Unpredictive (<0.02)
marital_status	0.0019	Unpredictive (<0.02)
totalcreditlimit	0.0016	Unpredictive (<0.02)
age	0.0015	Unpredictive (<0.02)
gender	0.0004	Unpredictive (<0.02)
public_records	0.0002	Unpredictive (<0.02)
loan_term	0.0001	Unpredictive (<0.02)

- 剔除标准：IV < 0.02 → 直接剔除（预测力不足）。IV > 0.5 → **不自动剔除**，仅标记为需要业务/公平信贷复核（"Suspicious / Overfitting"，可能是合法强预测因子，也可能是泄漏，取舍属于治理判断而非统计判断）。
- 弱预测力剔除（14 个）：*loanpurpose*, *educationlevel*, *monthlyincome*, *annualincome*, *loanamount*, *currentbalance*, *numofopenaccounts*, *installment*, *maritalstatus*, *totalcreditlimit*, *age*, *gender*, *publicrecords*, *loanterm*。

- 标记但保留入模（1 个）：`employment_status`——详见 §7.4 的治理复核说明。

3.2 多重共线性过滤（迭代式 VIF，内核为 `compute_vif_filter`，在 IV 筛选后特征的 WOE 编码矩阵上计算，`scripts/train.py`）

最终一轮（全部特征 $VIF \leq 5.0$ ）：

feature	vif
delinquency_history	3.86
numofdelinquencies	3.81
grade_subgrade	1.35
interest_rate	1.33
debttoincome_ratio	1.05
employment_status	1.01

- 剔除标准： $VIF > 5.0$ ，**每轮只剔除当前 VIF 最高的单个特征后重新计算**，而非一次性剔除所有超阈值特征（一次性剔除会在多个特征互相拖累对方 VIF 时过度剔除——本报告曾因此误伤 `credit_score`，见 §1）。
- 本次剔除特征（1 个，按剔除顺序）：`credit_score`。
- 完整迭代过程（共 2 轮）：

轮次 1：

feature	vif
credit_score	7.17
grade_subgrade	6.98
delinquency_history	3.86
numofdelinquencies	3.81
interest_rate	1.37
debttoincome_ratio	1.05
employment_status	1.01

轮次 2：

feature	vif
delinquency_history	3.86
numofdelinquencies	3.81
grade_subgrade	1.35
interest_rate	1.33
debttoincome_ratio	1.05
employment_status	1.01

3.3 最终入模特征（6 个）

employmentstatus, *debttoincomeratio*, *interestrate*, *gradesubgrade*, *delinquencyhistory*, *numof_delinquencies*

4. Hyperparameter Tuning (Optuna)

- 调优函数： `scripts/tune_lgb_skill.py` 的 `tune_lightgbm_optuna`（TPE 采样器， `random_state=42`）。
- 搜索空间： `learning_rate` $\in [0.01, 0.1]$ (log) , `num_leaves` $\in [15, 127]$, `max_depth` $\in [3, 8]$, `min_child_samples` $\in [20, 300]$, `subsample` $\in [0.6, 1.0]$, `colsample_bytree` $\in [0.6, 1.0]$, `reg_alpha` / `reg_lambda` $\in [1e-3, 10]$ (log) 。
- 交叉验证：5 折 `StratifiedKFold`（`shuffle=True`, `random_state=42`），每折内以验证集早停（`stopping_rounds=30`）；单调性约束 `monotone_constraints=[-1, -1, -1, -1, -1, -1]` 在每次试验中保持固定，与入模特征的 WOE 编码方向一致。
- 试验轮数：请求 50 轮，完成 50 轮。
- 优化目标：AUC（OOF，跨 5 折）。
- 最佳 CV AUC = **0.8862**。

4.1 最佳超参数配置

hyperparameter	value
learning_rate	0.054694
num_leaves	87
max_depth	4
minchildsamples	67
subsample	0.888127
colsample_bytree	0.896228
reg_alpha	0.00104463
reg_lambda	0.156011

4.2 最优模型特征重要度

feature	importance
grade_subgrade	912
debttoincome_ratio	562
employment_status	419
interest_rate	184
delinquency_history	121
numofdelinquencies	41

//

5. Model Performance & Discrimination

5.1 Train / Test 判别力对比表

(`evaluate_discrimination_and_ks` , `scripts/test.py`)

model	sample	AUC	Gini	KS	rating
Logistic Regression Scorecard (Baseline)	Train	0.8794	0.7588	0.5602	Good (0.40 - 0.60)
Logistic Regression Scorecard (Baseline)	Test	0.8812	0.7625	0.5717	Good (0.40 - 0.60)
Optuna-Tuned Monotonic LightGBM (Champion)	Train	0.8908	0.7817	0.5819	Good (0.40 - 0.60)
Optuna-Tuned Monotonic LightGBM (Champion)	Test	0.8858	0.7715	0.5777	Good (0.40 - 0.60)

- 内部阈值标准：Test 集 $KS \geq 0.3$, $AUC \geq 0.7$ 。
- 最优模型（Optuna 调优 LightGBM）Test 集结果： $AUC = 0.8858$ （PASS）， $KS = 0.5777$ （PASS），最优切点概率 = 0.2363。

5.2 评分卡标尺参数 (Baseline, `train_scorecard_model`, `scripts/train.py`)

- Base Points = 600, Base Odds = 50.0, PDO = 20
- Factor = 28.8539, Offset = 487.1229, Intercept = -1.4628

feature	logistic_coef	scoreimpactfactor
grade_subgrade	-1.6041	46.29
debttoincome_ratio	-1.5791	45.56
employment_status	-1.2759	36.82
delinquency_history	-0.3528	10.18
interest_rate	-0.3228	9.31
numofdelinquencies	0.2283	-6.59

5.3 混淆矩阵（最优模型，Test 集，切点 = KS 最优切点概率 0.2363）

	Predicted Bad (1)	Predicted Good (0)
Actual Bad (1)	823	378
Actual Good (0)	519	4280

metric	value
Accuracy	0.8505
Precision	0.6133
Recall / Sensitivity	0.6853
Specificity	0.8919

- 切点选取说明：Test 集违约率约 20%，固定 0.5 切点会导致模型几乎不触发正类预测；因此采用 `evaluate_discrimination_and_ks` 基于 ROC 曲线给出的 KS 最优切点概率（`argmax(TPR-FPR)`）作为混淆矩阵切点，而非任意的 0.5。

6. Population Stability Index (PSI)

6.1 模型分 PSI (最优模型预测违约概率, Train 作为基准分布, Test 作为实际分布, `scripts/test.py`)

- PSI = **0.0021**，状态：Stable (<0.10) - No action needed
- 监管标准：PSI < 0.10 无需处理；0.10~0.25 需特别注明预警；> 0.25 需模型重新校准。
本次结果：低于预警阈值，无需特别处理

6.2 关键特征 PSI (Train vs Test, Top 3 入模特征)

feature	PSI	status
debttoincome_ratio	0.0046	Stable (<0.10) - No action needed
interest_rate	0.0044	Stable (<0.10) - No action needed
delinquency_history	0.0005	Stable (<0.10) - No action needed

7. Explainability & Governance

7.1 全局 SHAP 特征重要性排序（`generate_shap_summary`，基于最优模型 LightGBM，Test 抽样 2000 条，`scripts/test.py`）

feature	meanabsshap
employment_status	1.7561
debttoincome_ratio	1.1506
grade_subgrade	1.0311
interest_rate	0.13
delinquency_history	0.0363
numofdelinquencies	0.0117

7.2 Top 3 特征业务解释

1. **employment_status**（△ 本报告 §7.4 单独讨论其治理风险）（平均 ISHAPI = 1.7561）：借款人就业状态（Employed / Self-employed / Retired / Student / Unemployed），起贷时可得的申请人属性，非模型输出的衍生字段；WOE 编码值越低代表原始取值落入历史违约率更高的分箱，对应模型预测违约概率上升。作为全局重要性排名第 1 的特征，建议在授信审批规则与额度定价中重点参考。
2. **debttoincome_ratio**（平均 ISHAPI = 1.1506）：借款人月负债与月收入的比值，比值越高代表偿债压力越大；WOE 编码值越低代表原始取值落入历史违约率更高的分箱，对应模型预测违约概率上升。作为全局重要性排名第 2 的特征，建议在授信审批规则与额度定价中重点参考。
3. **grade_subgrade**（平均 ISHAPI = 1.0311）：内部预分配风险评级子等级（30 档），与 `creditscore/DTI/interestrate` 等原始征信变量存在结构性重叠；WOE 编码值越低代表原始取值落入历史违约率更高的分箱，对应模型预测违约概率上升。作为全局重要性排名第 3 的特征，建议在授信审批规则与额度定价中重点参考。

7.3 敏感性分析：治理标记特征的边际贡献

对已保留但标记为 "Suspicious / Overfitting" 的特征（`employment_status`），重新拟合 Baseline 逻辑回归、剔除该特征后在同一 Test 集上重新评估，以量化其对判别力的边际贡献（口径对齐 `reports/PD_Model_Development_Document.docx` §7.3 的 variant 敏感性分析）：

variant	n_features	AUC	Gini	KS
Full set (incl. employment_status)	6	0.8812	0.7625	0.5717
Excluding employment_status	5	0.6979	0.3958	0.2764

该特征贡献了约 0.1833 的 Test AUC——是本模型判别力的主要来源，而非边际增益。这也是本模型判别力显著高于早前排除该特征版本（Test AUC ≈0.665）的核心原因。

7.4 治理标记特征明细（按类别）

employment_status（借款人就业状态（Employed / Self-employed / Retired / Student / Unemployed），起贷时可得的申请人属性，非模型输出的衍生字段）：

employment_status	n	default_rate	woe
Unemployed	1475	0.8203	-2.9045
Student	566	0.5866	-1.7357
Employed	9086	0.1133	0.6721
Self-employed	2021	0.1108	0.6964
Retired	852	0.007	3.5629

治理结论：该特征在起贷时可得、非模型输出的衍生字段，不构成技术意义上的标签泄漏；但其对模型判别力的贡献占比过高（集中度风险），且类别与借款人的就业/收入状态强相关，在放贷决策中使用可能构成对特定群体的间接歧视（disparate impact）。本报告将其保留入模用于性能评估，**但明确不建议在完成独立验证与公平信贷（fair-lending）合规复核之前将其用于实际授信决策。**参考文档：

`reports/PD_Model_Development_Document.docx` §8（同样保留该特征，同样将其列为待决限制项，尚未获得独立验证与合规批准）。

7.5 监管合规审查说明

- 模型类型：标准评分卡（L2 正则逻辑回归，`penalty='l2', C=1.0`）作为可解释性 Baseline，系数与标度均可追溯至 `Score = Offset + Factor * ln(Odds)` 公式；最优决策模型为 Optuna 调优后的单调约束 LightGBM。
- 最优模型（LightGBM）已对全部入模特征施加单调递减约束（`monotone_constraints=-1`），约束方向依据 WOE 编码定义（WOE 越高代表历史违约率越低），且该约束在 Optuna 全部 50 轮试验中保持固定，符合监管对评分类模型单调性的一般要求。
- 特征筛选与共线性处理均通过标准化流程（`calculate_woe_iv` / 迭代式

`compute_vif_filter`) 完成, 超参数寻优通过标准化流程

(`tune_lightgbm_optuna`) 完成, 未使用未经验证的第三方黑盒库直接输出模型结论。

- 判别力与稳定性指标 (KS/AUC/PSI) 均通过 `utils/risk_skills.py` 标准函数计算, 口径统一、可复现 (`random_state=42`) 。
- 训练/调参/测试边界可审计: `scripts/train.py` 只写 `artifacts/` (含 Optuna 调优过程), 从不读取 Test 集; `scripts/test.py` 只读 `artifacts/` 与 Test 集, 从不重新拟合分箱、编码器、模型参数或超参数。
- $IV > 0.5$ 的特征不再自动剔除, 改为保留入模 + 强制标记 + §7.3/§7.4 的量化敏感性分析与治理结论, 取舍留待模型使用方与合规团队决策, 而非由脚本单方面决定。